

# EXERCÍCIO Nº1 - RECONHECIMENTO DE CARACTERES COM MELHORIA DA TOLERÂNCIA A RUÍDOS

BRUNO A. DANTAS

*ENE, Universidade de Brasília*  
E-mail: brunoandregghetti@gmail.com  
Matrícula: 15/0007060

**Abstract**— This exercise is intended to show the importance of having a set of samples representative of the domain being classified when training feedforward neural networks to classify a set of symbols.

**Keywords**— Neural networks, feedforward, OCR, noise, dataset.

**Resumo**— Este exercício foi feito para mostrar a importância de se ter um conjunto de amostras capaz de representar bem o domínio sendo classificado ao treinar uma rede neural feedforward para classificar um conjunto de símbolos.

**Palavras-chave**— Redes neurais, feedforward, OCR, ruído, conjunto de dados.

## 1 Introdução

As redes neurais do tipo *feedforward* são aproximadores universais amplamente utilizados para implementação de classificadores. Um caso particular disso é a classificação de caracteres detectados em imagens ou OCR (*Optical Character Recognition*).

Na rede *feedforward*, um conjunto de entradas é inserido na rede através da camada de entrada, somado ponderadamente em cada neurônio intermediário e no resultado é aplicada a função de ativação correspondente ao neurônio. O mesmo é feito na camada seguinte com as saídas da camada anterior até que se obtenha a saída final da rede no formato desejado pelo projetista.

Para ajustar os pesos de cada neurônio é utilizado o algoritmo de *backpropagation*, onde é calculado o gradiente do erro em relação a cada um dos pesos de cada neurônio, movendo-o no sentido contrário a fim de minimizar o erro.

A função que determina o erro é chamada de função de custo ou função de perda.

## 2 Implementação

Para simplificar a implementação do OCR, podemos representar os caracteres através de matrizes binárias de tamanho 7x9 pixels. Deste modo, são possíveis  $2^{63}$  combinações (9.22 quintilhões) para representar um caractere qualquer.

Deste modo, queremos dividir esse espaço em 16 grupos tal que a rede neural seja capaz de reconhecer caracteres mesmo quando ele for afetado por ruído.

Como é possível observar na Figura 1, os caracteres - mesmo com um índice de ruído baixo como 10% - já se tornam difíceis de se reconhecer em alguns dos casos.



Figura 1: Caracteres com 10% de ruído e originais.

Foi utilizado o framework Keras para Python 3.6 para implementação e treinamento da rede e a biblioteca PyPlot para obtenção dos gráficos necessários.

A rede foi treinada em etapas. Primeiramente foi feito um treinamento apenas com os caracteres originais e copiada a rede para uma seguinte.

Com a rede seguinte, inicializada com os pesos da anterior, foram executadas 200 épocas de treinamento com 15 conjuntos de caracteres ruidosos diferentes, inicialmente com 10% de ruído. Após as 200 épocas, foi feito um treinamento para que a rede “se lembrasse” dos caracteres originais, de apenas 10 épocas.

O processo foi repetido aumentando-se o ruído nos caracteres usados para o treinamento até que se obtivesse 6 redes, cada uma treinada com ruído maior que a anterior.

## 3 Resultados

Após o treinamento as redes foram testadas com novos conjuntos de caracteres ruidosos, produzindo o gráfico da Figura 2.

## Referências Bibliográficas

Keras Framework. <https://keras.io/>  
PyPlot documentation.  
[https://matplotlib.org/api/pyplot\\_summary.html](https://matplotlib.org/api/pyplot_summary.html)

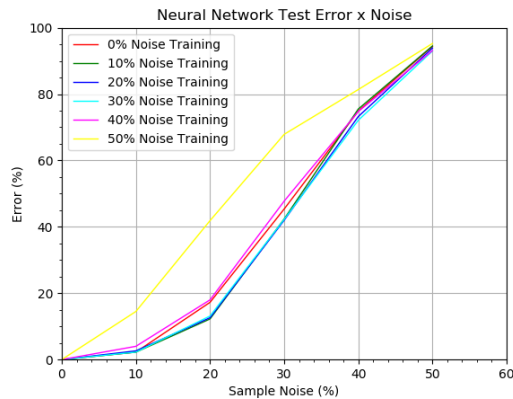


Figura 2: Erro na etapa de teste

Como é possível perceber, as redes treinadas com 10%, 20% e 30% de ruído mostraram melhor desempenho ao classificar amostras mais ruidosas.

As redes treinadas com muito ruído, como 40% e especialmente 50%, mostraram desempenho bastante inferior devido ao fato de que com essa quantidade de ruído a informação contida nos pixels é praticamente apagada.



Figura 3: Caracteres com 20% de ruído classificados pela rede treinada com 20% de ruído.

Na Figura 3 é possível observar que a rede treinada com 20% de ruído foi capaz de reconhecer até mesmo caracteres que, para humanos, não se assemelham de forma alguma com os caracteres originais. Isso mostra a capacidade de generalização da rede.

## 3 Conclusão

Com o exercício foi possível observar a importância de um conjunto de amostras amplo que represente o domínio do problema sendo abordado.

Embora as redes treinadas com alto ruído tenham mostrado desempenho ruim, foi possível observar que as redes que foram treinadas com 10%, 20% e até 30% de ruído foram capazes de generalizar os novos conjuntos ruidosos com melhor desempenho que a rede que havia treinado apenas com os caracteres originais.

Os resultados comprovam a hipótese de que um bom conjunto de amostras representativo do domínio do problema abordado é essencial para o bom desempenho de uma rede neural como a implementada neste exercício.