

EXERCÍCIO 5 - CONTROLE NARMA-L2 DE PROCESSO DE NÍVEL

BRUNO ANDREGHETTI DANTAS*

Email: brunoandreggetti@gmail.com

Abstract— The purpose of this exercise is to simulate a NARMA-L2 controller applied to a second-order liquid level system and compare the performance with different hyperparameters.

Keywords— NARMA, Control Systems, MATLAB, Liquid Level, Simulink.

Resumo— Este exercício visa simular um controlador NARMA-L2 para controle de nível de líquidos de segunda ordem e comparar o desempenho com diferentes hiperparâmetros.

Palavras-chave— NARMA, Controle, MATLAB, Liquid Level, Simulink.

1 Introdução

Processos de nível de líquido são exemplos clássicos utilizados no estudo de controle não-linear. Além de ser um processo naturalmente lento e portanto sem necessidade de controladores capazes de lidar com altas frequências no sistema real, é também um processo muito presente na indústria.

Embora seja possível lidar com a não-linearidade do sistema através dos métodos tradicionais, é muito utilizado também o modelo discreto NARMA (Nonlinear Auto-Regressive Moving Average), capaz de identificar e controlar sistemas utilizando redes neurais.

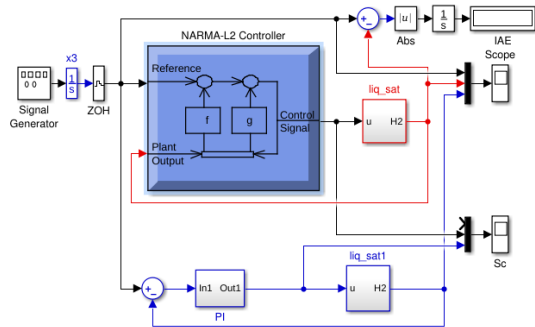


Figura 1: Malha de controle utilizando NARMA-L2.

O treinamento da rede é realizado offline através dos dados provenientes de um ensaio que pode ser simulado ou realizado em uma planta real. Durante a execução, a única computação realizada é o processo de *feedforward* para cálculo do sinal de controle. (Pukrittayakamee et al., 2002)

2 Metodologia e Desenvolvimento

Para desenvolvimento do exercício foi utilizado o MATLAB R2017a e suas ferramentas para desenvolvimento de redes neurais artificiais, além do Simulink para simulação do sistema de nível de líquido.

2.1 Treinamento

Os hiperparâmetros considerados nesse exercício são divididos em duas naturezas. Os 3 primeiros listados na Tabela 1 são referentes à topologia da rede utilizada para modelar o controlador. Já 2 últimos são referentes à dinâmica do sistema controlado: o período de amostragem sendo o tempo entre cada leitura do sistema e atualização do controlador e o intervalo máximo sendo o período máximo em que a entrada aleatória da simulação realizada para obtenção dos dados de treinamento pode permanecer constante.

Para realização do comparativo dos hiperparâmetros, foram selecionadas 6 configurações, definidas na Tabela 1. As configurações foram baseadas em experimentos prévios onde foram obtidos parâmetros razoáveis de base - os da configuração 1 - e em seguida foram alterados os parâmetros pouco a pouco buscando obter melhorias no resultado.

Configuração	1	2	3	4	5	6
Nº de neurônios	10	15	15	10	10	15
Nº de entradas defasadas	4	4	4	4	4	4
Nº de saídas defasadas	4	4	8	4	8	6
Período de amostragem (s)	10	10	10	5	5	10
Intervalo Máximo (s)	250	250	250	250	250	100

Tabela 1: Configurações testadas.

Para avaliação de cada configuração, foi medida a Integral do Erro Absoluto (IEA) como função de custo. Como referência, foi feita a simulação de um controlador PI que atingiu uma IEA de 445.6.

Após a simulação, a configuração de melhor IEA foi simulada para obtenção das Figuras 2 e 3.

3 Resultados

A IEA de cada uma das configurações testadas está disposta na Tabela 2. A configuração 6 obteve melhor resultado, embora sua IEA seja apenas 1.3% inferior à do segundo melhor resultado, da configuração 2.

Configuração	1	2	3	4	5	6
IEA	361.6	351.4	360.4	371.6	367.3	346.7

Tabela 2: Integral do Erro Absoluto para cada configuração.

A seguir foram obtidos os gráficos das Figuras 2 e 3.

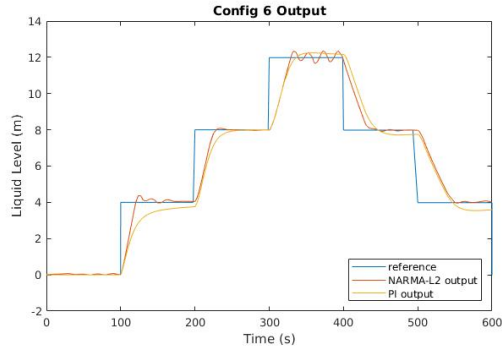


Figura 2: Simulação dos controladores NARMA-L2 e PI.

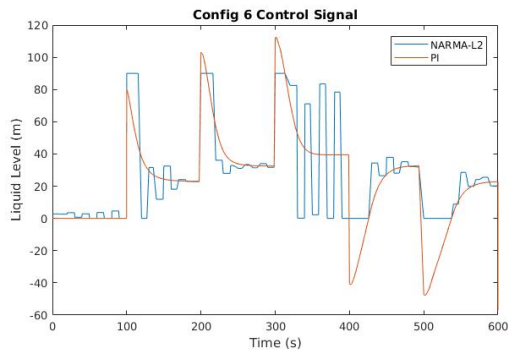


Figura 3: Sinal de controle dos controladores NARMA-L2 e PI.

4 Análise e Conclusões

A escolha dos parâmetros se mostrou um desafio, uma vez que algumas das configurações apresentadas nem sempre alcançavam um desempenho aceitável no primeiro treinamento. Muitas vezes foi necessário reiniciar os pesos do controlador para que o treinamento convergisse para valores adequados.

A escolha do parâmetro de intervalo máximo para a configuração 6 foi devida ao fato de que o período de mudança do sinal de entrada utilizado na simulação era de 100 segundos, portanto escolhendo 100 segundos como intervalo máximo para a obtenção dos dados de simulação garantiria que não haveriam situações em que o sinal permaneceria constante por muito tempo.

Já os parâmetros de rede foram ajustados junto ao período de amostragem. Uma amostra-

gem mais rápida exigiria uma rede com mais atrasos do sinal de entrada e saída para obter informações sobre a mesma janela de tempo. Além disso, com mais valores de entrada da rede neural, mais neurônios seriam necessários para reconhecer adequadamente os padrões presentes no conjunto de treinamento.

Além, é importante destacar que a complexidade da rede - ou seja, o número de neurônios e de atrasos do sinal de entrada e de saída - deve permanecer dentro de uma janela ótima. Uma rede muito complexa pode ser difícil de treinar e é mais propensa ao *overfitting*. Já uma rede muito simples pode ser incapaz de aproximar as funções necessárias para o funcionamento correto do controlador NARMA-L2.

Por fim, é importante observar que embora a IAE do controlador NARMA-L2 tenha sido inferior à do controlador PI, é possível observar no gráfico da Figura 3 que seu sinal de controle é consideravelmente mais ruidoso, podendo levar a um desgaste dos componentes de uma planta real que utilize esse tipo de controlador.

Referências

- Pukrittayakamee, A., De Jesús, O. and Hagan, M. T. (2002). Smoothing the control action for narma-l2 controllers, *Circuits and Systems, 2002. MWSCAS-2002. The 2002 45th Midwest Symposium on*, Vol. 3, IEEE, pp. III-III.